

Optimización del Sector Salud con Redes Neuronales Profundas: Predicción de Enfermedades Cardiovasculares

Juan Pablo Daza Pereira
Nicolas Bernal Fuquene
Saray Alieth Mendivelso Gonzalez

Mayo 2025

Abstract

El artículo explora el uso de la inteligencia artificial en especial las redes neuronales artificiales y el aprendizaje automático para la predicción de enfermedades cardiovasculares en pacientes. Se presenta un análisis detallado sobre el impacto que tienen estas enfermedades en la tasa de mortalidad a nivel mundial. Se describe cómo la inteligencia artificial ha revolucionado el sector de la salud y de la medicina mediante el análisis de grandes cantidades de datos clínicos disponibles, permitiendo la detección temprana de enfermedades y mejorando la precisión para el diagnóstico de éstas. Finalmente, se analizan los desafíos a la hora de implementar estas tecnologías, como lo son la calidad y disponibilidad de los datos, las implicaciones éticas y políticas, y la necesidad de capacitar a todo el personal médico especialista en cardiología para que haga uso adecuado de estas herramientas. Se concluye, para terminar, que aunque existen ciertos obstáculos, la IA es una solución prometedora para mejorar la prevención y el tratamiento de enfermedades cardiovasculares, y que tiene el potencial de transformar la atención médica del futuro.

Palabras clave: Inteligencia artificial, redes neuronales, enfermedades cardiovasculares, predicción, diagnóstico, aprendizaje automático, salud.

Contents

1	Introducción	2
2	Estado de Arte	3
3	Descripción y caracterización del problema	5
4	Marco Teórico	7

5 Descripción de Solución	9
6 Resultados y Evaluación	13
7 Conclusiones	20

1 Introducción

Las enfermedades cardiovasculares representan a día de hoy una de las principales causas de mortalidad en todo el mundo, siendo responsables de más o menos el 32% de las muertes de 2019. El impacto de estas enfermedades sigue en aumento, impulsado por factores como pueden ser el envejecimiento de la población o la mala alimentación. Además, cada vez es más normal ver estilos de vida poco saludables, y esto ha hecho que el número de personas que sufren enfermedades cardiovasculares aumente. Es importante tener en cuenta que la detección temprana y un tratamiento oportuno son clave para poder reducir la mortalidad y poder darles un mejor tratamiento a los pacientes [1].

El uso de inteligencia artificial en la industria de la salud está estrechamente relacionado con el concepto de medicina personalizada, que básicamente trata acerca de que el tratamiento se adapta a las necesidades específicas de cada paciente, en base a su historia clínica personal. Gracias a la inteligencia artificial, podríamos transformar la medicina, mejorando no solo la precisión del diagnóstico, sino también mejorando todo el sistema de salud por completo. Se espera que en un futuro no tan lejano, las herramientas predictivas jueguen un papel muy importante, a la hora de diagnosticar y prevenir enfermedades cardiovasculares, permitiéndoles así a los profesionales de la salud ofrecer tratamientos más rápidos y efectivos[2].

Aun así, a pesar de lo mucho que ha avanzado la medicina, los sistemas de salud se siguen enfrentando a importantes desafíos en la detección temprana y el diagnóstico de las enfermedades cardiovasculares. En muchos países, existen limitaciones debido a la falta de tecnología y a la escasez de personal que esté bien preparado para realizar los diagnósticos. Todo esto, nos lleva a pensar en la necesidad de nuevas innovaciones tecnológicas que nos ayuden a facilitar el diagnóstico y la prevenir muertes por este tipo de enfermedades.

Nuestro proyecto tiene como objetivo principal optimizar el sector de la salud mediante el uso de redes neuronales para la predicción de enfermedades cardiovasculares por medio de un dataset clínico (combinado) que cuenta con más de 100.000 datos de pacientes con y sin enfermedades cardiovasculares. Buscamos lograr la detección temprana de este tipo de enfermedades, para poder reducir los costos de los tratamientos y mejorar el servicio ofrecido por hospitales. Todo esto en base a la implementación de modelos predictivos que estén basados en inteligencia artificial, con lo cual esperamos mejorar la atención médica que se ofrece y ofrecer mejores herramientas en la lucha contra las enfermedades cardiovasculares.

2 Estado de Arte

Panorama Actual

Las enfermedades cardiovasculares (ECV) son una de las principales causas de mortalidad en el mundo, lo que ha impulsado el desarrollo de nuevas tecnologías capaces de mejorar la prevención, diagnóstico y tratamiento. En este contexto, la inteligencia artificial, y en particular las redes neuronales artificiales, han demostrado tener un gran potencial para transformar el sector de la salud, gracias a la capacidad que tienen estas redes de procesar grandes cantidades de datos clínicos y de generar predicciones más precisas. Este estado del arte revisa los avances más relevantes en la aplicación de la IA para el diagnóstico y predicción de ECV.

Avances Recientes

Uno de los hallazgos que encontramos es la capacidad que tienen los modelos predictivos basados en redes neuronales para identificar factores de riesgo con mayor precisión que los métodos tradicionales. Investigaciones recientes demuestran que estos modelos pueden analizar grandes volúmenes de datos clínicos, como antecedentes médicos, análisis de laboratorio e imágenes cardíacas, permitiendo una detección temprana de enfermedades cardíacas.

Un estudio realizado por un grupo de profesionales colombianos, se encargó de realizar un análisis comparativo entre distintas técnicas de inteligencia artificial, entre ellas redes neuronales, Random Forest y Árbol de decisión, con el propósito de evaluar cuál de estas era la más eficaz al momento de predecir enfermedades cardiovasculares. Los resultados fueron los siguientes:

Técnica ML	accuracy	precision	recall	F1-Score
Decision tree	82%	82%	81%	81%
Random Forest	85%	85%	85%	85%
Neural Networks	89%	89%	89%	89%

Figure 1: Comparación de técnicas de aprendizaje automático para la predicción del riesgo cardiovascular. Fuente: *Cardiovascular risk prediction through machine learning: a comparative analysis of techniques*

En donde podemos observar que las redes neuronales son indiscutiblemente el mejor modelo de los tres, sobresaliendo en las tres métricas que se usaron para medir la eficacia de cada modelo, “accuracy” que representa el porcentaje promedio de predicciones correctas al usar el modelo, “precisión” que se centra

en minimizar el número de falsos negativos, por lo tanto, mientras menos falsos negativos, mejor, y “recall” que en cambio se enfoca en reducir al máximo los falsos positivos.[3].

Otro estudio muy interesante es el realizado por un grupo de investigadores de Cambridge en el año 2019, quienes centraron su estudio en la posibilidad de usar Machine Learning para la predicción de enfermedades cardiovasculares, a partir de los datos recolectados de 423.604 voluntarios de Reino Unido.

Desarrollaron un modelo de Machine Learning, llamado AutoPrognosis, para predecir el riesgo de sufrir enfermedades cardiovasculares, basándose en 473 variables, variables que normalmente no se toman en cuenta para la predicción de este tipo de enfermedades como puede ser el ritmo de caminata de la persona, y luego lo compararon con algoritmos de predicción ya conocidos como el Framingham Score, que calcula el riesgo de sufrir una enfermedad cardiovascular en los próximos 10 años.

En términos generales, los resultados obtenidos en el estudio demostraron, que AutoPrognosis produjo mejores resultados de predicción, según lo expuesto por ellos mismos, de todos los casos registrados en 5 años, AutoPrognosis pudo predecir correctamente 368 casos más que lo logrado por el Framingham Score [4]. A nivel más general, se destaca el uso creciente de big data en conjunto con IA, permitiendo el análisis de datos clínicos estructurados y no estructurados para una detección más temprana de patologías. Otra tendencia relevante es la integración de la IA con tecnologías de telemedicina y dispositivos portátiles, facilitando el monitoreo remoto y personalizado del paciente.

Justificacion Para Nuestra Propuesta

Los hallazgos indican que los modelos basados en redes neuronales ofrecen mejoras significativas en la precisión de diagnósticos y en la reducción de la carga de trabajo médico. Sin embargo, persisten limitaciones importantes como la falta de interpretabilidad de los modelos, la disponibilidad de datos clínicos de calidad, y la resistencia a la adopción tecnológica dentro del personal de salud. Asimismo, muchos estudios se han enfocado en validaciones experimentales con datasets cerrados, sin una implementación real en entornos clínicos, ni un despliegue efectivo de estos modelos como herramientas accesibles para profesionales. Tampoco se observa una incorporación clara de estas tecnologías en infraestructuras de nube o en interfaces que faciliten su uso por personal no técnico.

Nuestro proyecto busca contribuir al estado del arte mediante el desarrollo de un modelo predictivo basado en redes neuronales feedforward, integrado en un dashboard web interactivo y desplegado en AWS. Esta propuesta busca no solo validar el modelo desde una perspectiva técnica, sino también acercarlo a su uso real mediante una interfaz intuitiva para profesionales de la salud, contribuyendo así a la transformación digital del sector.

3 Descripción y caracterización del problema

Explicación

1. Contexto Actual

Las enfermedades cardiovasculares (ECV) representan una de las principales causas de mortalidad en Colombia y a nivel mundial. Factores como el envejecimiento de la población, el sedentarismo, la mala alimentación y la predisposición genética han incrementado su prevalencia. Es por esto que la detección temprana y el tratamiento oportuno son esenciales para reducir la morbilidad y mejorar la calidad de vida de los pacientes.

Según la Organización Mundial de la Salud (OMS), aproximadamente, más de 20,5 millones de personas mueren cada año debido a enfermedades cardiovasculares, representando el 32 % de muertes a nivel global.




Figure 2: Tendencia de mortalidad. Fuente: <https://cuentadealtocosto.org/general/dia-mundial-del-corazon-2024/Cuenta> de Alto Costo.

De estas, más del 85% se deben a ataques cardíacos y accidentes cerebrovasculares. La carga económica de estas enfermedades es inmensa, con costos estimados en cientos de miles de millones de dólares anuales en atención médica y pérdida de productividad.

Ahora sí hablamos de Colombia, en el año 2019, se registraron 38.475 muertes por enfermedades isquémicas del corazón y 15.543 por enfermedades cerebrovasculares, según datos del Departamento Administrativo Nacional de Estadística DANE [5].

Además, la urbanización acelerada ha promovido estilos de vida poco saludables, lo que ha aumentado la incidencia de enfermedades crónicas. En muchos países, los sistemas de salud enfrentan limitaciones en la capacidad de detección temprana debido a la falta de tecnología accesible y la carencia de personal capacitado para interpretar grandes volúmenes de datos clínicos. Aunado a esto,

la prevalencia de factores de riesgo como la hipertensión arterial es alarmante; estudios indican que en Colombia, el 36,4% de la población adulta padece esta condición. Según un informe elaborado por Deloitte Access Economics en colaboración con la Federación Mundial del Corazón el costo económico asociado a las ECV es significativo, pues en 2015, se estimó que Colombia destinó aproximadamente \$2,4 mil millones de dólares (alrededor de 6,4 billones de pesos colombianos) al tratamiento de enfermedades cardíacas, representando el 6,6% del gasto total en salud. [6]

Country	Prevalence (% 20+ population)	Financial cost (USDbn)	Health cost (% financial)	Productivity loss (% GDP)
Brazil	32.0%	17.3	5.5%	0.4%
Chile	38.0%	1.4	4.2%	0.2%
Colombia	17.4%	2.4	6.6%	0.3%
Ecuador	14.0%	0.6	2.5%	0.4%
El Salvador	27.3%	0.2	8.5%	0.3%
Mexico	25.6%	6.1	3.6%	0.3%
Panama	29.0%	0.3	3.4%	0.3%
Peru	16.0%	0.9	2.1%	0.4%
Venezuela	33.4%	1.7	2.2%	0.2%

Figure 3: Costos Económicos Asociados a las ECV. Fuente: [chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://world-heart-federation.org/wp-content/uploads/2017/05/spanish-press-release.pdf](https://world-heart-federation.org/wp-content/uploads/2017/05/spanish-press-release.pdf)Cuenta de Alto Costo.

2. Problemática

A pesar de los avances médicos, existen bastantes desafíos en la identificación y prevención de las ECV:

- **Diagnóstico tardío:** En muchos casos, los pacientes no presentan síntomas hasta que la enfermedad está en una fase avanzada. La falta de datos regulares y pruebas diagnósticas accesibles contribuye a diagnósticos tardíos y a un aumento en la tasa de complicaciones. Según estudios recientes., En 2022, Colombia registró un aumento del 35% en muertes por ECV en comparación con 2021, pasando de 51.988 a más de 70.000 fallecimientos [7].
- **Altos costos de tratamiento:** Las pruebas diagnósticas y las intervenciones cardiovasculares resultan ser costosas para los pacientes y los sistemas de salud. Además, el tratamiento de enfermedades cardiovasculares implica un uso significativo de recursos hospitalarios, lo que puede derivar en saturación de los servicios de atención médica. En 2015, el infarto de miocardio fue la afección con mayor costo financiero en Colombia, estimado en \$3,4 billones de pesos. Además, se proyecta que los costos asociados a las enfermedades crónicas no transmisibles, incluyendo las ECV, aumentarán en un 40% en términos reales entre 2022 y 2030 [8].

- **Gestión ineficiente de recursos:** La falta de herramientas predictivas dificulta la asignación eficiente de recursos en hospitales y aseguradoras de salud. Esto genera desperdicio de insumos, tiempos de espera prolongados y limitaciones en la cobertura de atención para pacientes en riesgo [9].
- **Datos no aprovechados:** Aunque existen grandes volúmenes de datos clínicos, muchas veces no son utilizados de manera efectiva para la toma de decisiones. La falta de infraestructura para almacenar, procesar e interpretar estos datos limita el desarrollo de estrategias de prevención basadas en evidencia. Actualmente, se estima que más del 80% de los datos clínicos no se analizan de manera efectiva para mejorar la atención médica [10].
- **Disparidades en el acceso a la salud:** En regiones con menor acceso a tecnologías avanzadas, la detección de enfermedades cardiovasculares es menos efectiva. Factores socioeconómicos pueden influir en la capacidad de los pacientes para recibir atención adecuada y en el seguimiento de tratamientos preventivos. Según informes de la OMS, las tasas de mortalidad por ECV son hasta tres veces más altas en países de bajos ingresos en comparación con países de altos ingresos [11].

Ante estos desafíos, la aplicación de tecnologías como la inteligencia artificial y las redes neuronales ofrece una solución prometedora para mejorar la detección temprana, optimizar los costos y mejorar la eficiencia del sistema de salud.

4 Marco Teórico

El siguiente marco teórico sienta las bases para el análisis de la implementación de la IA en la predicción de enfermedades cardiovasculares:

Inteligencia artificial en la medicina

La inteligencia artificial ha revolucionado el sector de la salud ya que ha automatizado ciertos procesos a partir de grandes cantidades de datos. El aprendizaje automático, una rama de IA, y las redes neuronales artificiales han demostrado gran eficacia en la predicción de enfermedades ya que es capaz de identificar ciertos patrones en grandes volúmenes de datos clínicos [12].

Redes neuronales y su aplicación en el diagnóstico de enfermedades

Las redes neuronales artificiales son modelos inspirados en el funcionamiento del cerebro humano. Estas redes se componen de múltiples capas de neuronas interconectadas que permiten la detección de relaciones complejas en grandes cantidades de datos.

En el sector médico y de la salud, las redes neuronales artificiales han sido útiles para la predicción de enfermedades para poder dar una mejor personalización en el tratamiento de la enfermedad[13].

Algoritmos de aprendizaje automático para la predicción de enfermedades cardiovasculares

Distintos algoritmos de machine learning han sido usados para la predicción de enfermedades cardiovasculares, entre ellos están:

- **Regresión logística:** Se utiliza en modelos estadísticos para estimar la probabilidad de padecer cierta enfermedad.
- **Máquinas de soporte vectorial (SVM):** Permiten clasificar datos en función de características relevantes (ingeniería de características).
- **Árboles de decisión y random forest:** Estos son modelos de clasificación que analizan múltiples variables en la toma de decisiones médicas.
- **Redes neuronales profundas (Deep Learning):** Estas redes son más precisas en la predicción por su uso de capas de procesamiento no lineales [14].

Big data

El concepto de big data en la salud se refiere al estudio y análisis de grandes cantidades de datos médicos que buscan mejorar el diagnóstico y tratamiento de enfermedades. El combinar IA con Big Data, facilita la creación de modelos predictivos basados en toda esa cantidad de datos disponibles [4].

Desafíos en la implementación de la IA en la especialización de cardiología

Implementar estas tecnologías trae desafíos como la interpretabilidad de los distintos modelos, la calidad de los datos clínicos, la ética y la regularización de las políticas de uso de la IA y la resistencia al cambio dentro del sector de la salud [4].

Aprendizaje profundo (Deep Learning)

El aprendizaje profundo es una subrama del aprendizaje automático que utiliza redes neuronales con múltiples capas ocultas, lo que permite detectar patrones complejos no lineales en grandes cantidades de datos [15].

Redes neuronales feedforward (FNN)

Las redes neuronales feedforward son uno de los tipos más simples de redes neuronales artificiales. La información fluye solo en una dirección —de entrada a salida— sin ciclos. Son ampliamente utilizadas en clasificación binaria y regresión, y han demostrado ser eficaces en problemas donde los datos están estructurados y tabulados [16].

5 Descripción de Solución

La solución propuesta es un sistema inteligente para el diagnóstico temprano de enfermedades cardiovasculares mediante el análisis de dos datasets:

- Cardiovascular Disease Dataset (Kaggle): Este dataset contiene información médica tabular de pacientes con el objetivo de predecir la presencia o ausencia de enfermedades cardiovasculares. Cuenta con una cantidad de 70.000 datos y 13 variables (age, gender, height, weight, BMI, systolic/diastolic pressure, cholesterol, gluc, smoke, alco, active y cardio) donde la etiqueta de salida es 0 (cero) para no enfermedad y 1 (uno) para con enfermedad. El balance del dataset tiene un desbalance leve donde hay un 47% de los datos para positivos (con enfermedad) y el 53% para negativos (sin enfermedad).
- CAD Cardiac MRI Dataset (Kaggle): Este dataset contiene imágenes MRI del corazón, utilizadas para segmentación y clasificación de patologías cardíacas. Cuenta con 63425 datos de distintos pacientes, cada uno con imágenes en 3D adquiridas en fases de sistole y diastole del ciclo cardiaco, de los cuales 37564 son de imágenes normales (pacientes sanos) y el resto son de imágenes de pacientes con CAD (enfermedades arteriales coronarias). Cada paciente tiene una etiqueta asignada, cada uno es para un caso distinto, donde 0 es para no enfermedad, 1 para infarto de miocardio, 2 para miocardiopatía dilatada, 3 para miocardiopatía hipertrofica, y finalmente, 4 para displasia ventricular derecha.

El sistema implementa una arquitectura en la nube, utilizando servicios de AWS que serán explicados más adelante en las arquitecturas.

El núcleo de solución es un modelo híbrido de inteligencia artificial que combina una red neuronal convolucional (CNN) para el procesamiento de imágenes de resonancia magnética (MRI) con una red neuronal densa (FNN) para los datos clínicos. Ambos modelos son integrados mediante un módulo de ensamblaje que genera la predicción.

Explicación de la solución

1. Entrenamiento de los modelos

- Se entrenan los modelos por separado.
- Se extrae la salida latente (embedding) de cada modelo (última capa antes de la salida).
- Se concatena la salida de la CNN y la FNN.
- Esa concatenación alimenta a una red final (modelo ensamblador).

2. Arquitecturas

- Arquitectura empresarial:

– Flujo:

- * **Acceso del Usuario (Especialista Médico y Paciente):** Los pacientes y médicos acceden al sistema a través de la interfaz web (frontend), autenticados mediante Amazon Cognito, que gestiona el acceso seguro y basado en roles.
- * **Carga de Datos del Paciente:** A través de la interfaz, el paciente o el médico pueden completar un formulario con datos clínicos y cargar imágenes de resonancia magnética cardíaca (MRI).
- * **Hosting y Entrega del Frontend:** La interfaz web está alojada de forma estática en Amazon S3 y distribuida globalmente mediante Amazon CloudFront.
- * **Envío de datos a la API REST (Back-end):** Los datos clínicos e imágenes son enviados mediante Amazon API Gateway, que canaliza las solicitudes hacia una función en AWS Lambda.
- * **Validación y Preprocesamiento (Back-end):** AWS Lambda realiza validaciones y preprocesamiento de los datos antes de enviarlos a los modelos de inteligencia artificial.
- * **Predicción con Modelos de IA:** Los datos clínicos se procesan mediante una red neuronal feedforward (FNN), mientras que las imágenes MRI son analizadas por una red neuronal convolucional (CNN). Un servicio ensamblador integra ambos resultados para generar una predicción unificada.
- * **Generación del Resultado:** El sistema emite un diagnóstico automatizado con una probabilidad estimada de enfermedad cardiovascular.
- * **Almacenamiento de Resultados:** Las imágenes MRI se almacenan en un bucket S3 específico, mientras que los datos clínicos y predicciones se registran en Amazon DynamoDB.
- * **Visualización de Resultados:** Los médicos acceden al Dashboard Médico para revisar los resultados, mientras que personal de gestión accede al Dashboard Admin. Ambos están protegidos con autenticación basada en Amazon Cognito.
- * **Acceso del Científico de Datos:** El científico de datos accede directamente a la base de datos DynamoDB para analizar resultados y ajustar modelos o estrategias de diagnóstico.




Figure 4: Arquitectura empresarial desarrollada.

- Arquitectura del prototipo:

- Flujo:

- * **Usuario:** Accede a través de una interfaz web donde introduce sus datos clínicos y carga una imagen de resonancia magnética (MRI).
- * **Frontend Web:** Presenta un formulario interactivo y facilita la carga de la imagen. Los datos son enviados a la API.
- * **API REST (Flask):** Encargada de validar los datos, preprocesarlos y enviarlos a los modelos correspondientes para la inferencia.
- * **Modelos de IA:** FNN (Feedforward Neural Network) procesa los datos clínicos estructurados y CNN (Convolutional Neural Network) analiza la imagen médica (MRI). Ambos modelos están previamente entrenados y almacenados en un bucket de Amazon S3.
- * **Ensamblaje CNN + FNN:** Los resultados intermedios se combinan en una capa de fusión que genera una predicción conjunta más precisa.
- * **Resultado:** Se genera un diagnóstico con probabilidad asociada. Este resultado se guarda en DynamoDB junto con los datos originales y almacena la imagen MRI en Amazon S3.
- * **Dashboard de Visualización:** Una interfaz gráfica (dashboard) accede a los datos en DynamoDB para mostrar resultados individuales o agregados.

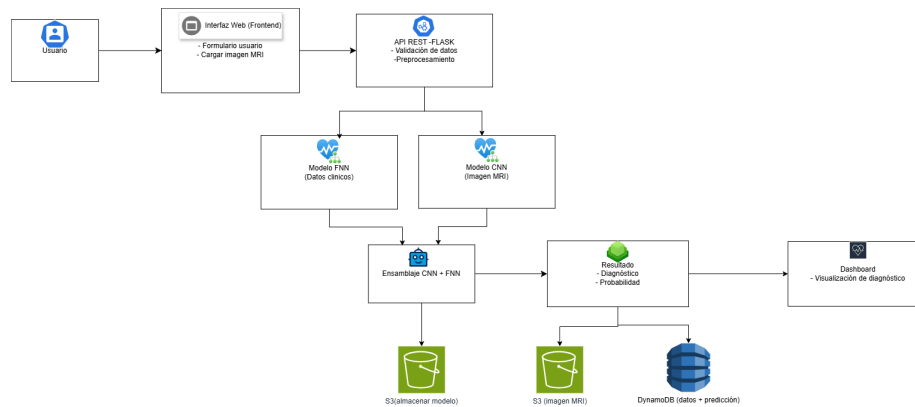


Figure 5: Arquitectura del prototipo desarrollada.

3. Diseño del dashboard del prototipo: Se utilizará Flask/Streamlit para construir una interfaz sencilla e intuitiva donde los usuarios puedan ingresar datos y visualizar resultados en tiempo real.

Ejemplo de uso

1. Un profesional de la salud accede a la interfaz web y completa el formulario con los datos clínicos del paciente. Además, carga una imagen de resonancia magnética cardíaca (MRI) reciente.
2. La aplicación envía la información recopilada a través de una API REST desplegada en AWS. Esta API valida y preprocesa los datos antes de enviarlos a los modelos predictivos alojados en la nube.
3. Los datos clínicos se procesan mediante una red neuronal feedforward (FNN), mientras que la imagen MRI es analizada por una red convolucional (CNN). Los resultados de ambos modelos se combinan en un servicio de ensamblaje, generando una predicción integral.
4. El sistema devuelve un diagnóstico automatizado junto con una probabilidad estimada de riesgo cardiovascular. Esta información se almacena de forma segura y es visualizada en tiempo real en un dashboard médico, donde el especialista puede analizar el resultado y tomar decisiones clínicas fundamentadas.

Casos de uso

1. Hospitales que necesitan un sistema ágil para diagnóstico temprano.
2. Clínicas con poco personal que requieren ayuda de IA para prediagnóstico.
3. Plataformas de salud remota o telemedicina.

6 Resultados y Evaluación

Resultados del Modelo FNN

Los resultados de entrenamiento muestran un comportamiento óptimo del modelo propuesto. Las curvas de pérdida y precisión revelan varios aspectos importantes sobre el rendimiento del modelo.

El análisis de la función de pérdida indica una convergencia rápida y estable. Inicialmente, tanto la pérdida de entrenamiento como la de validación decrecen significativamente durante las primeras 10 épocas, estabilizándose posteriormente alrededor de 0.55. Esta tendencia demuestra que el modelo aprende eficientemente los patrones subyacentes en los datos sin mostrar signos de sobreajuste (overfitting).

La precisión del modelo alcanza valores satisfactorios, con un rendimiento de aproximadamente 73.8% en el conjunto de entrenamiento y 73.2% en el conjunto de validación. La proximidad entre estos valores es particularmente relevante, ya que indica que el modelo generaliza adecuadamente a datos no vistos previamente. Las pequeñas oscilaciones observadas en la precisión de validación sugieren que el proceso de aprendizaje es robusto, aunque podrían mitigarse con ajustes adicionales en los hiperparámetros.

Un aspecto destacable es la ausencia de divergencia entre las curvas de entrenamiento y validación, lo que confirma que las técnicas de regularización empleadas (L2, dropout) y los callbacks implementados (early stopping, reducción de learning rate) funcionan correctamente para prevenir el sobreajuste.



Figure 6: Pérdida y precisión del modelo.

La matriz de confusión del modelo proporciona información adicional sobre su rendimiento clasificatorio. El análisis revela que:

Rendimiento en la clase "No Cardio":

- Verdaderos negativos: 4,038 (76.8%)
- Falsos positivos: 1,166 (22.2%)

Rendimiento en la clase "Cardio":

- Verdaderos positivos: 3,492 (68.5%)
- Falsos negativos: 1,610 (31.5%)

El modelo demuestra mayor precisión identificando casos sin enfermedad cardiovascular (especificidad más alta), lo cual es común en problemas de clasificación médica donde los casos negativos suelen ser más frecuentes. La sensibilidad (capacidad de detectar casos positivos) es del 68.5%, indicando que el modelo identifica correctamente aproximadamente 7 de cada 10 casos de enfermedad cardiovascular.




Figure 7: Matriz de confusión.

La curva ROC muestra un desempeño sólido con un AUC de 0.80, lo que indica una capacidad de discriminación buena entre las dos clases. Este valor se interpreta como:

- $AUC > 0.8$: Buen poder discriminativo.
- La curva se eleva rápidamente desde el origen, sugiriendo que el modelo puede lograr alta sensibilidad manteniendo una especificidad razonable.

- La distancia significativa de la línea diagonal (clasificador aleatorio) confirma que el modelo aporta valor predictivo real.




Figure 8: Curva ROC y Área Bajo la Curva (AUC).

Resultados del Modelo CNN

Los resultados de entrenamiento muestran un comportamiento excepcional del modelo CNN propuesto. Las curvas de pérdida y precisión revelan aspectos muy positivos sobre el rendimiento del modelo:

Función de Pérdida:

La curva de pérdida evidencia una convergencia óptima. Inicialmente, tanto la pérdida de entrenamiento como la de validación decrecen rápidamente durante las primeras 4 épocas, estabilizándose posteriormente. La pérdida de entrenamiento alcanza valores muy bajos (0.25), mientras que la pérdida de validación se mantiene estable alrededor de 0.15-0.2. Es particularmente notable que no existe divergencia entre las curvas, indicando que no hay sobreajuste significativo.

Precisión:

El modelo alcanza un rendimiento excepcional, con aproximadamente 95% de precisión en el conjunto de validación al final del entrenamiento. La progresión es consistente: la precisión inicia en 50% y aumenta rápidamente hasta estabi-

lizarse en valores muy altos. La proximidad entre las curvas de entrenamiento y validación confirma que el modelo generaliza correctamente.




Figure 9: Análisis de las Curvas de Entrenamiento.

La matriz de confusión revela un rendimiento sobresaliente en el conjunto independiente de prueba:

Rendimiento por clase:

- Clase Normal (Especificidad): 3,435 verdaderos negativos vs 445 falsos positivos (88.5% de especificidad)
- Clase CAD (Sensibilidad): 3,763 verdaderos positivos vs 116 falsos negativos (97.0% de sensibilidad)

El modelo muestra una sensibilidad excepcional (97%) para detectar casos de CAD, lo cual es crucial en aplicaciones médicas donde no detectar una enfermedad puede tener consecuencias graves. La especificidad del 88.5% también es satisfactoria, indicando que el modelo no genera excesivos falsos positivos.




Figure 10: Matriz de Confusión del Conjunto de Prueba.

La curva ROC presenta resultados extraordinarios con un AUC de 0.99, indicando una capacidad de discriminación casi perfecta. Esta métrica confirma que:

- El modelo supera ampliamente cualquier clasificador aleatorio
- La curva se eleva casi verticalmente desde el origen, sugiriendo que se puede lograr alta sensibilidad con una tasa de falsos positivos muy baja
- El rendimiento discriminativo es excepcional en todo el rango de umbrales

Resultados de la Implementación (Modelo Híbrido + Frontend + Backend)

Los resultados de la implementación de nuestra solución y propuesta, son buenos y acorde a casos reales, para comprobar que la aplicación estuviera funcionando correctamente y ver que tan preciso era en la practica real, probamos con varios casos de personas que no padecen ni han sido diagnosticadas con enfermedades cardiovasculares y también con personas que si están diagnosticadas con enfermedades cardiovasculares, incluyendo no solo los datos requeridos por la aplicación como edad, presión, colesterol o glucosa, sino que también, por supuesto

sus respectivas imágenes MRI, parte fundamental para la predicción.



Figure 11: Imagen MRI de un paciente sano.



Figure 12: Resultado de la predicción paciente sano.




Figure 13: Imagen MRI de un paciente con CAD.



Figure 14: Resultado de la predicción paciente enfermo.

Al hacer estas pruebas no solo obtuvimos los resultados esperados, en cuanto a las predicciones ofrecidas por la aplicación, sino que observamos que la predicción es generada en muy poco tiempo, lo cual es perfecto, ya que buscamos que nuestra app pueda ofrecer no solo resultados ciertos sino de forma rápida y sencilla. También decidimos dar a probar nuestra aplicación a algunas personas ajenas al desarrollo de la misma, para poder recibir retroalimentación de elementos como la interfaz gráfica o la dificultad de uso de la misma, en términos generales, las reacciones y respuestas fueron buenas, entre las recomendaciones que recibimos, resaltamos la posibilidad de incrementar el número de campos para intentar cubrir ciertas variables menos generales, o también aunque no pudimos contar con la opinión de un doctor en esta ocasión, nos mencionaron que podría ser buena idea dejar un espacio para que el doctor encargado pudiera añadir síntomas o detalles adicionales que el pueda considerar relevantes para el análisis.

7 Conclusiones

Después de realizar el trabajo de investigación expuesto en este artículo, podemos concluir que las redes neuronales parecen ser una herramienta excepcional para la detección temprana de enfermedades cardiovasculares. Los resultados obtenidos así lo demuestran:

Modelo de Red Neuronal Feedforward: Alcanzó una precisión del 73.2% con un AUC de 0.80, demostrando capacidad efectiva para clasificar factores de

riesgo cardiovascular. La ausencia de sobreajuste y la estabilidad en las métricas de entrenamiento y validación confirman su robustez.

Modelo CNN para Imágenes MRI: Mostró resultados sobresalientes con 95% de precisión, 97% de sensibilidad para detectar CAD, y un AUC de 0.99. Estos valores posicionan el modelo como una herramienta casi perfecta para el análisis de imágenes médicas.

Estos resultados evidencian que las redes neuronales son capaces de identificar y analizar grandes cantidades de datos complejos extrayendo patrones que serían difíciles de detectar con métodos tradicionales. Esto tiene un impacto muy importante, ya que permitirá mejorar significativamente la eficacia y eficiencia de los diagnósticos cardiovasculares.

También podría traer consigo otros beneficios como pueden ser, una reducción de costos operativos para hospitales y centros médicos, aunque seguramente a largo plazo y no de manera inmediata, o también una reducción de responsabilidad y carga de trabajo para los médicos que decidan apoyarse en estas tecnologías. Específicamente, el modelo CNN podría servir como primera línea de screening, permitiendo a los radiólogos enfocar su atención en casos más complejos.

Los datos obtenidos sugieren aplicaciones inmediatas: el modelo de factores de riesgo puede integrarse en sistemas de registro médico electrónico para evaluación continua de pacientes, mientras que el modelo CNN puede implementarse en departamentos de radiología para asistencia diagnóstica.

Aunque como ya mencionamos anteriormente, integrar inteligencia artificial en un campo como el de la salud parece bastante prometedor, también debemos mencionar que parecen haber varios desafíos por delante para lograr que esto funcione, por ejemplo, la capacitación que deberá recibir el personal y el tiempo de adaptación para acomodarse a esta nueva ola de tecnología, algo que podría no ser fácil para todos, pero que es importante abordar, porque estas tecnologías nuevas llegaron para quedarse.

Por último, debemos mencionar que todo parece dar a entender que en el futuro (seguramente no tan lejano), la inteligencia artificial irá siendo más y más importante para los tratamientos, diagnósticos y en general para la toma de decisiones médicas, incluyendo por supuesto las enfermedades cardiovasculares. Los resultados de alta precisión obtenidos (AUC de 0.80 y 0.99 respectivamente) demuestran que esta tecnología ya está alcanzando niveles de rendimiento comparables o superiores a métodos tradicionales. La tecnología seguirá mejorando y nosotros no debemos quedarnos atrás, sino continuar adaptándonos y haciendo uso de ello lo mejor posible, aprovechando las ventajas comprobadas que estos modelos pueden ofrecer para mejorar la atención cardiovascular.

References

- [1] O. M. de la Salud, “Enfermedades cardiovasculares,” 2021.
- [2] E. J. Topol, “High-performance medicine: the convergence of human and artificial intelligence,” *Nature Medicine*, vol. 25, no. 1, pp. 44–56, 2019.

- [3] W. Arrubla-Hoyos, F. Carrascal-Porras, and J. E. Gómez, “Predicción de riesgo cardiovascular mediante aprendizaje automático: un análisis comparativo entre técnicas,” *Ingeniería y Competitividad*, vol. 26, no. 1, 2024.
- [4] A. M. Alaa, T. Bolton, E. Di Angelantonio, J. H. Rudd, and M. Van der Schaar, “Cardiovascular disease risk prediction using automated machine learning: A prospective study of 423,604 uk biobank participants,” *PloS one*, vol. 14, no. 5, p. e0213653, 2019.
- [5] “DANE - las enfermedades cardiovasculares son la primera causa de muerte en colombia y el mundo.” <https://www.bayer.com/es/co/las-enfermedades-cardiovasculares-son-la-primera-causa-de-muerte-en-colombia-y-el-mundo>. [Accessed 18-02-2025].
- [6] W. H. Federation, “Gasto por enfermedades cardiovasculares en colombia,” *World Heart Federation*, 2017. Accedido el 9 de mayo de 2025.
- [7] “Estudios recientes - colombia registró un aumento del 35% en muertes por enfermedades cardiovasculares durante el último año.” <https://www.infobae.com/colombia/2023/09/29/colombia-registro-un-aumento-del-35-en-muertes-por-enfermedades-cardiovasculares-durante-el-ultimo-ano/>. [Accessed 18-02-2025].
- [8] “Costo financiero - colombia invierte 64 billones al año en tratar enfermedades cardíacas.” <https://consultorsalud.com/colombia-invierte-64-billones-al-ano-en-tratar-enfermedades-cardiacas/>. [Accessed 18-02-2025].
- [9] “Gestión ineficiente de recursos - optimización de la asignación de camas en hospitales mediante tecnología.” <https://www.ft.com/content/0d6188d8-9238-4276-92b1-33b65ac64577>. [Accessed 18-02-2025].
- [10] “Datos no aprovechados - la ia adelanta el diagnóstico de sepsis en 24 horas en un hospital de mallorca.” <https://elpais.com/sociedad/2024-09-01/la-ia-ya-salva-vidas-en-un-hospital-de-mallorca-con-un-algoritmo-que-pronto-se-extendera-a-otros.html>. [Accessed 18-02-2025].
- [11] “Disparidades en el acceso a la salud - las desigualdades socioeconómicas y su impacto en la salud global.” <https://elpais.com/extra/eventos/2024-10-20/alertas-rojas-para-la-salud.html>. [Accessed 18-02-2025].
- [12] D. Estévez and J. A. Gutiérrez, “Aplicaciones de la inteligencia artificial en cardiología: el futuro ya está aquí,” *Revista Española de Cardiología*, vol. 72, no. 12, pp. 1065–1075, 2019.
- [13] M. A. C. Arias, A. M. Saiquita, G. S. Flores, T. V. Pérez, *et al.*, “Predicción de enfermedades cardiovasculares utilizando redes neuronales artificiales,” *XIKUA Boletín Científico de la Escuela Superior de Tlahuelilpan*, vol. 12, no. Especial, pp. 89–94, 2024.

- [14] W. Arrubla-Hoyos, F. Carrascal-Porras, and J. E. Gómez, “Predicción de riesgo cardiovascular mediante aprendizaje automático: un análisis comparativo entre técnicas,” *Ingeniería y Competitividad*, vol. 26, p. e-20113229, feb. 2024.
- [15] <https://www.oracle.com/co/artificial-intelligence/machine-learning/what-is-deep-learning/>. [Accessed 26-03-2025].
- [16] “Qué son las redes neuronales y sus aplicaciones — OpenWebinars — openwebinars.net.” <https://openwebinars.net/blog/que-son-las-redes-neuronales-y-sus-aplicaciones/>. [Accessed 26-03-2025].